

PROFESSOR: Marco Aurélio Lima Barbosa	
CURSO: Ciência da Computação	
DISCIPLINA: Análise Descritiva de Dados	
TURMA: Noturno	DATA:
ALUNO(A): Bruno Rodrigues Da Costa, Guilherme Monteiro Da Silva, João Pedro Da Silva, Stefany Samira De Oliveira Cubertino	

TÍTULO DA ATIVIDADE: Análise Descritiva de Dados – Gestão de Fisioterapia

Link para a planilha utilizada:  [ALINHA +] - Analise Descritiva

https://docs.google.com/spreadsheets/d/1OwkCFNbUDsI0_-4fhKr7Sn6WpSm7tpkyXgTcj8GkP7E/edit?usp=sharing

BOXPLOTS:  Boxplots.pdf

<https://drive.google.com/file/d/1LB1neCzsyn3HNyMpCAfbCovTY1kPmuKs/view?usp=sharing>

Este trabalho dá continuidade à análise descritiva do banco de dados simulado da **Clínica Maya Yamamoto RPG**. Na entrega anterior, foram identificadas as variáveis, calculadas médias e percentis. Nesta segunda etapa, avaliamos a **dispersão dos dados** por meio do Coeficiente de Variação (CV), identificamos as variáveis com maior variabilidade, sugerimos medidas de redução, realizamos a **análise exploratória por boxplots** com identificação e descarte de outliers, concluímos sobre a concentração dos dados e calculamos **probabilidades de eventos** relevantes para a gestão clínica.

1. Coeficiente de Variação (CV)

O Coeficiente de Variação é uma medida que serve para saber o quanto os dados estão espalhados em relação à média. A vantagem dele é que, como é dado em porcentagem, dá pra comparar variáveis com unidades diferentes — como idade e número de sessões, por exemplo. A fórmula é:

$$CV = (\text{Desvio Padrão} \div \text{Média}) \times 100$$

De forma geral, quando o CV é menor que 15% os dados são bem homogêneos; entre 15% e 30% a dispersão é moderada; e acima de 30% considera-se que há **grande dispersão**. Os resultados estão na tabela abaixo:

Variável	Coefficiente de Variação (CV)	Classificação	Dispersão
Faltas	112,07%	CV > 100%	Extrema
Tempo de Tratamento (dias)	55,05%	CV > 30%	Alta
Número de Sessões	41,46%	CV > 30%	Alta
Nível de Dor Inicial	33,14%	CV > 30%	Alta
Idade	32,41%	CV > 30%	Alta
Peso (kg)	13,84%	CV < 30%	Baixa
Altura (cm)	4,16%	CV < 30%	Baixa

2. Variáveis com Grande Dispersão

Com base nos CVs calculados, cinco variáveis ficaram acima dos 30% e merecem atenção. Vamos analisar cada uma delas:

Faltas (CV = 112,07%)

Essa foi a variável com maior dispersão de todas, muito acima do esperado. O CV de 112% acontece porque a média de faltas é baixa (0,82) mas tem pacientes que faltaram muito mais do que a maioria — alguns chegaram a 3 faltas. Isso faz com que a média não represente bem a realidade, já que boa parte dos pacientes não faltou nenhuma vez.

Tempo de Tratamento (CV = 55,05%)

Os tratamentos variam bastante em duração: tem paciente que ficou só 12 dias e outro que ficou 100 dias. Essa diferença grande faz sentido quando a gente leva em conta que cada caso é diferente — pacientes com problemas simples terminam rápido, enquanto casos mais crônicos demoram muito mais.

Número de Sessões (CV = 41,46%)

O número de sessões variou de 4 a 20, com CV de 41%. A lógica é parecida com o tempo de tratamento: casos mais leves precisam de menos sessões, enquanto os mais graves precisam de muito mais acompanhamento. Isso gera bastante variação em torno da média.

Nível de Dor Inicial (CV = 33,14%)

A dor inicial dos pacientes variou de 2 a 9 na escala de 0 a 10. É um número que já era esperado ser disperso, já que cada pessoa chega na clínica com uma queixa diferente — uns chegam com dor leve, outros com dor bem intensa. Essa variação influencia diretamente o tipo de tratamento prescrito.

Idade (CV = 32,41%)

A faixa etária dos pacientes vai de 19 a 64 anos, o que já mostra por que o CV é alto. A clínica atende desde adultos jovens até pessoas mais velhas, o que naturalmente gera uma variação grande nas idades.

3. Sugestões para Reduzir a Variabilidade

Para cada variável com alta dispersão, pensamos em algumas ações que a clínica poderia tomar para tentar reduzir essa variabilidade e melhorar os resultados:

Faltas

Problema: Poucos pacientes concentram muitas faltas, distorcendo os números.

O que pode ser feito: Mandar lembretes automáticos por WhatsApp ou SMS antes das sessões; criar um acompanhamento específico para quem faltou mais de 1 vez; facilitar o reagendamento para não perder o paciente; tentar entender o perfil de quem falta pra ver se tem algum padrão (horário, região da dor, etc.).

Tempo de Tratamento e Número de Sessões

Problema: Cada caso tem uma duração muito diferente, dificultando o planejamento da clínica.

O que pode ser feito: Criar protocolos por tipo de diagnóstico com uma estimativa de duração esperada; fazer reavaliações periódicas dos casos que estão passando do tempo previsto; registrar os resultados de cada tratamento para melhorar as estimativas futuras.

Nível de Dor Inicial

Problema: Pacientes chegam com intensidades de dor muito diferentes, exigindo abordagens distintas.

O que pode ser feito: Usar sempre a mesma escala de avaliação de dor (EVA) na triagem; criar três categorias de protocolo por faixa de dor (leve, moderada e severa); garantir que toda a equipe avalie da mesma forma para manter a consistência dos dados.

4. Análise dos Boxplots e Outliers

O boxplot é um gráfico que mostra como os dados estão distribuídos. Ele indica a mediana (valor do meio), os quartis Q1 e Q3, e os chamados **outliers** — que são os valores que ficam muito fora do padrão.

$$\text{Limite Inferior} = Q1 - 1,5 \times (Q3 - Q1) \quad | \quad \text{Limite Superior} = Q3 + 1,5 \times (Q3 - Q1)$$

Qualquer valor que esteja fora desses limites é considerado um outlier e pode ser descartado da análise para que a média fique mais representativa. Veja os resultados abaixo:

Variável	Q1	Mediana	Q3	Limite Sup.	Outliers encontrados	Efeito na média
Tempo de tratamento (dias)	25	35	49,5	86,25	90, 95 e 100 dias	39,2 → 35,6 dias
Faltas	0	1	1	2,5	3 faltas (3 pacientes)	0,82 → 0,68 faltas
Altura (cm)	167,6	171,35	175,6	187,6	188,0 e 189,5 cm	171,91 → 171,21 cm
Idade	30,25	39,5	50,75	81,5	Nenhum	—
Peso (kg)	66,0	73,75	81,0	103,5	Nenhum	—
Nível de dor inicial	4,25	6,0	7,0	11,13	Nenhum	—
Número de sessões	8	10	14	23	Nenhum	—

A variável com outliers mais impactantes foi o **tempo de tratamento**: três pacientes ficaram com 90, 95 e 100 dias de tratamento, bem acima do limite de 86,25 dias. Sem eles, a média cai de 39,2 para 35,6 dias — uma diferença relevante. Em **faltas**, três pacientes tiveram 3 faltas cada, passando do limite de 2,5. Ao retirá-los, a média de faltas cai de 0,82 para 0,68, mostrando que a aderência geral é ainda melhor do que parece. Já em **altura**, os outliers (188,0 e 189,5 cm) têm pouco efeito prático na média, que muda apenas de 171,91 para 171,21 cm.

5. Concentração dos Dados

Para saber se os dados estão concentrados em valores maiores ou menores, comparamos a **média com a mediana** de cada variável. Quando a média é maior que a mediana, significa que a maioria dos valores está abaixo da média — ou seja, os dados se concentram em valores mais baixos, e alguns casos extremos altos "puxam" a média pra cima. Quando a média é menor que a mediana, o contrário acontece.

Variável	Média	Mediana	Diferença	Conclusão
Tempo de Tratamento (dias)	39,20	35,00	+4,20	Concentra em valores baixos , a maioria trata rápido, poucos casos longos puxam a média pra cima
Número de Sessões	10,72	10,00	+0,72	Leve concentração em valores baixos , a maioria faz até 10 sessões
Idade	40,46	39,50	+0,96	Leve concentração em valores baixos , há alguns pacientes mais velhos puxando a média
Altura (cm)	171,91	171,35	+0,56	Distribuição bem equilibrada , média e mediana muito próximas
Faltas	0,82	1,00	-0,18	Distribuição bem equilibrada , média e mediana praticamente iguais
Nível de Dor Inicial	5,72	6,00	-0,28	Distribuição bem equilibrada , leve tendência a valores mais altos
Peso (kg)	73,62	73,75	-0,13	Distribuição simétrica , dados muito bem distribuídos

De modo geral, as variáveis que mais mostram concentração em valores baixos são o **tempo de tratamento** e o **número de sessões**: a maioria dos pacientes termina o tratamento em menos tempo e com menos sessões do que a média sugere, mas alguns casos mais complexos ficam por muito mais tempo e "puxam" a média pra cima. As demais variáveis têm médias e medianas bem próximas, indicando uma distribuição mais equilibrada.

6. Probabilidade de Ocorrência de Eventos

Para calcular as probabilidades, usamos a **frequência relativa** — ou seja, dividimos o número de pacientes que se encaixam na condição pelo total de pacientes (50). Essa é a forma mais direta de estimar a chance de um evento acontecer com base nos dados que temos.

Fórmula: Probabilidade = (Nº de pacientes com a condição ÷ Total de pacientes) × 100

Evento	Pacientes	Total	Probabilidade
Faltar mais de 1 vez	11	50	22,0%
Faltar mais de 2 vezes	3	50	6,0%
Faltar mais de 3 vezes	0	50	0,0%
Realizar mais de 15 sessões	7	50	14,0%
Realizar mais de 18 sessões	3	50	6,0%
Realizar mais de 20 sessões	0	50	0,0%
Tratamento acima de 60 dias	7	50	14,0%
Chegar com dor inicial ≥ 7	19	50	38,0%

Os resultados mostram que cerca de **1 em cada 5 pacientes** (22%) falta mais de uma vez — um número relevante para justificar ações de acompanhamento. Faltar mais de 2 vezes já é bem raro (6%), e nenhum paciente na amostra faltou mais de 3 vezes. Em relação às sessões, apenas 14% dos pacientes ultrapassam 15 sessões, e menos de 1 em 20 passa de 18. Por fim, quase **4 em cada 10 pacientes** chegam à clínica com dor alta (7 ou mais na escala), o que reforça a necessidade de protocolos para casos mais intensos.

7. Conclusão

Com essa segunda entrega conseguimos ter uma visão mais completa do banco de dados da clínica. A análise do coeficiente de variação mostrou que cinco variáveis têm grande dispersão: faltas, tempo de tratamento, número de sessões, nível de dor e idade. Isso indica que o perfil dos pacientes é bastante variado, o que é natural numa clínica que atende diferentes tipos de queixa.

A análise dos boxplots identificou outliers principalmente em tempo de tratamento e faltas. Ao descartar esses valores extremos, as médias ficam mais representativas do paciente típico — o que é importante para o planejamento da clínica não ser distorcido por casos excepcionais.

A comparação entre média e mediana mostrou que a maioria das variáveis tem dados mais concentrados em valores baixos, com casos extremos puxando as médias para cima. Isso reforça a importância de olhar não só para a média, mas também para a mediana na hora de tomar decisões.

Por fim, as probabilidades calculadas apontam que cerca de 22% dos pacientes faltam mais de uma vez e que poucos ultrapassam 18 sessões. Esses números são úteis para a clínica definir quando acionar protocolos de acompanhamento especial — tanto para melhorar a aderência quanto para identificar casos mais complexos que precisam de atenção diferenciada.